

Capítulo 1 panorama ML

Este capítulo presenta una visión general de Machine Learning y también sirve como una introducción a los conceptos que se desarrollan más adelante en los siguientes capítulos, incluyendo importantes conceptos y definiciones. Géron explica que el aprendizaje automático permite que las computadoras aprendan a partir de datos y mejoren el desempeño en una tarea sin la necesidad de programar manualmente todas las reglas. Tener una gran cantidad de información almacenada no significa que exista Machine Learning; por ejemplo, podemos descargar toda una enciclopedia o diccionario, que solo tendremos mucha información, mas no aporta más que almacenamiento y no resuelve tareas; debe existir un aprendizaje que permita mejorar alguna tarea.

Una de las razones principales para utilizar ML es que existen situaciones demasiado complejas para resolverlas únicamente por reglas tradicionales, un ejemplo es detección de spam, en lugar de crear continuamente las reglas para identificar nuevos tipos de mensajes, un modelo puede aprender de ejemplos anteriores y reconocer patrones que indiquen si un correo es spam, ya que se podrían omitir palabras consideradas spam para así saltar las reglas previamente escritas. Esos sistemas pueden adaptarse a los cambios y ayudar a descubrir los patrones que no son evidentes.

Se clasifican los sistemas de ML de diferentes maneras, según la supervisión, pueden ser

- supervisados, cuando trabajan con datos que tienen respuestas conocidas;
- no supervisados, cuando buscan patrones en datos sin etiquetas;
- semisupervisados, cuando combinan ambos tipos de información;
- aprendizaje por refuerzo, donde un agente aprende mediante acciones, recompensas y penalizaciones.

También pueden diferenciarse por la forma en que reciben datos:

- aprendizaje por lotes utiliza los datos disponibles para entrenar el modelo,
- aprendizaje online permite actualizarlo progresivamente conforme llegan nuevos datos.

Finalmente, existen sistemas basados en instancias, que comparan nuevos casos con ejemplos conocidos, y sistemas basados en modelos, que construyen una representación matemática para realizar predicciones.

Otro tema importante son los problemas que pueden afectar el rendimiento de un modelo. Los datos pueden ser insuficientes, poco representativos, de baja calidad o contener características que no aportan información útil. Por lo que la ingeniería de características resulta para seleccionar, combinar o crear variables relevantes. Hay que mencionar otros problemas en los modelos como el sobreajuste que ocurre cuando un modelo es demasiado complejo y se aprende incluso el ruido de los datos, contrario al sub-ajuste que aparece cuando el modelo es muy simple y no se logra

representar adecuadamente la información. Técnicas como la regularización ayuda a controlar la complejidad del modelo.

Los datos suelen dividirse en entrenamiento y prueba y también puede utilizarse un conjunto de validación para seleccionar modelos e hiperparámetros sin utilizar directamente los datos destinados a la evaluación final.

La validación cruzada nos permite realizar varias evaluaciones utilizando diferentes partes de los datos, es importante considerar que los datos utilizados para entrenar un modelo pueden ser diferentes de los que encontrará posteriormente en las circunstancias reales.

No Free Lunch: según el cual no existe un algoritmo que sea siempre el mejor para todos los problemas. La elección del modelo depende de las características de los datos y del problema que busca resolver.

Este capítulo funciona como una guía para comprender conceptos fundamentales

- aprendizaje supervisado y no supervisado,
- sobreajuste,
- subajuste,
- regularización,
- validación,
- parámetros
- hiperparámetros.

Capítulo 2 Proyecto de Machine Learning de principio a fin

El capítulo 2 muestra cómo llevar los conceptos del capítulo 1 a un proyecto real de ML utilizando el dataset “California Housing Prices”. Con el objetivo es predecir el precio medio de las viviendas de diferentes distritos en California a partir de variables como: ingresos, población, número de habitaciones y cercanía al océano. Se presenta un proceso completo que puede utilizarse como guía para desarrollar otros proyectos de ML.

El primer paso consiste en entender el problema desde el punto de vista del negocio para luego definir qué se quiere predecir y para qué se utilizará la predicción y hasta qué tipo de problema se estara resolviendo. Se trata de un problema de aprendizaje supervisado y de regresión, y se busca predecir un valor numérico. El proceso general incluye obtener los datos, explorarlos, prepararlos, seleccionar modelos, ajustarlos, evaluar la solución y desplegarla y monitorearla.

Para evaluar los modelos de regresión se utiliza principalmente RMSE, que penaliza más errores grandes, aunque puede utilizarse el MAE si existen muchos valores atípicos. Otro aspecto es crear correctamente un conjunto de prueba. En vez de seleccionar datos solamente al azar, el libro muestra la utilidad del muestreo estratificado que permite conservar proporciones de la población y obtener un conjunto de prueba representativo.

Una vez separado el conjunto de prueba, se exploran los datos mediante gráficos y estadísticas. Adicionalmente, ubicación y cercanía al océano muestra una relación importante con los precios, mientras que el ingreso medio presenta una correlación especialmente alta.

Sin embargo, el autor recuerda que la correlación de Pearson solamente identifica relaciones lineales y no siempre representa correctamente relaciones más complejas. Se encontraron algunos valores artificiales producidos por la forma en que se recopilaron los datos. A partir de esa exploración se realizó ingeniería de características, creando variables nuevas: habitaciones por hogar o dormitorios por habitación, que pueden resultar más útil que variables originales.

Seguidamente se preparan los datos para los algoritmos. Scikit-Learn facilita el proceso mediante estimadores, transformadores y predictores:

- para los valores faltantes se utiliza SimpleImputer;
- para variables categóricas se utiliza One-Hot Encoding, y
- para las variables numéricas se pueden aplicar técnicas de escalado como Min-Max Scaling o estandarización.

Estas transformaciones se organizan mediante Pipeline y ColumnTransformer, lo que permite construir procesos de preparación ordenados, reproducibles y fáciles de reutilizar.

En la etapa de selección de modelos se prueban diferentes alternativas. La regresión lineal presenta un error elevado, lo que indica que el modelo es demasiado simple para representar adecuadamente el problema y existe underfitting.

Por otro lado, un árbol de decisión obtiene un error prácticamente perfecto sobre los datos de entrenamiento, pero esto resulta sospechoso porque puede estar memorizando los ejemplos.

Mediante validación cruzada se puede comprobar que el desempeño con datos nuevos es peor para posteriormente, un Random Forest, el cual consigue mejores resultados al combinar múltiples árboles.

El capítulo explica cómo:

- mejorar un modelo mediante el ajuste de hiperparámetros.
- Herramientas como GridSearchCV permiten probar sistemáticamente diferentes combinaciones
- RandomizedSearchCV resulta útil cuando existen demasiadas posibilidades.
- También pueden combinarse varios modelos mediante técnicas de ensamble.
- Una vez seleccionado el modelo definitivo, el conjunto de prueba debe utilizarse solamente al final para obtener una evaluación imparcial.

Conclusión, el capítulo presenta una metodología completa para desarrollar proyectos de ML:

- comprender el problema,
- obtener y explorar los datos, prepararlos,
- entrenar diferentes modelos,
- utilizar validación cruzada,
- ajustar hiperparámetros,
- evaluar finalmente el modelo y monitorearlo después de su implementación

La principal enseñanza es que un modelo que funciona muy bien con los datos de entrenamiento no necesariamente funcionará adecuadamente con datos nuevos; por eso, la capacidad de generalización y una correcta evaluación.