

Capítulo 5 **Support Vector Machines (SVM)**

Uno de los algoritmos más versátiles de ML. Las SVM pueden utilizarse para clasificación lineal y no lineal, regresión e incluso detección de valores atípicos. Son especialmente útiles en conjuntos de datos pequeños o medianos con estructuras complejas.

La idea principal de una SVM para clasificación es encontrar una frontera que separe las clases dejando el **mayor margen posible** entre ellas. En lugar de buscar una línea que divida los datos, el algoritmo intenta crear una especie de “calle” lo más ancha posible. Las observaciones que se encuentran en los límites de esta calle son los **vectores de soporte**, ya que son las que determinan principalmente la posición de la frontera. Por esa razón, las observaciones alejadas de ella tienen poca o ninguna influencia sobre el modelo. Las SVM son sensibles a las escalas de las variables, por lo que es regularmente necesario estandarizar los datos antes de entrenarlas.

Se analizan dos tipos de margen:

- El margen duro exige que todas las observaciones estén correctamente clasificadas y fuera del margen, pero puede fallar cuando los datos no son perfectamente separables y resulta muy sensible a los valores atípicos.
- El margen suave permite algunas violaciones para encontrar un equilibrio entre un margen amplio y un número reducido de errores. Este equilibrio se controla mediante el hiperparámetro **C**. Un **C** pequeño permite más errores y genera una mayor regularización, mientras que un **C** grande intenta clasificar correctamente más observaciones, aunque puede aumentar el riesgo de sobreajuste.

Cuando los datos no pueden separarse mediante una frontera lineal, existen diferentes alternativas, una consiste en agregar características polinómicas para transformar los datos y hacer posible una separación lineal, mientras otra, mucho más eficiente, es utilizar el **kernel trick**. Esta técnica permite obtener el efecto de trabajar en un espacio de características de mayor dimensión sin tener que calcular explícitamente todas esas características, reduciendo considerablemente el costo computacional.

Uno de los kernels más importantes es el **RBF o kernel Gaussiano**, que mide la similitud entre las observaciones y determinados puntos de referencia. Su comportamiento depende del hiperparámetro **gamma (γ)**:

- Un gamma alto produce una influencia más localizada y fronteras de decisión más complejas, aumentando el riesgo de overfitting.
- Un gamma bajo genera una influencia más amplia y fronteras más suaves, aunque puede producir underfitting.

Por lo tanto, tanto **C** como gamma influyen en la complejidad y capacidad de generalización del modelo.

Se explica que no todos los kernels tienen el mismo costo computacional. **LinearSVC** resulta mucho más eficiente cuando existen grandes cantidades de observaciones o características, mientras que **SVC** permite utilizar kernels más complejos, pero puede volverse muy lento cuando el número de observaciones aumenta considerablemente. Como estrategia práctica, se recomienda

comenzar con un kernel lineal y probar posteriormente el kernel RBF cuando el tamaño del dataset lo permita.

Las SVM también pueden utilizarse para **regresión**. En este caso, en lugar de buscar una separación entre clases, el objetivo es construir una “calle” alrededor de las predicciones y mantener dentro de ella la mayor cantidad posible de observaciones. El parámetro **epsilon (ϵ)** determina el ancho de esta zona. Las observaciones que permanecen dentro del margen no generan una penalización, lo que hace que la regresión SVM sea *ϵ -insensitive*. Existen versiones lineales y versiones que utilizan kernels para problemas no lineales.

Conclusión, la principal característica de las SVM es que plantean el aprendizaje desde una perspectiva **geométrica**, buscando maximizar el margen entre las clases. Conceptos como:

- los vectores de soporte,
- el margen suave,
- C,
- los kernels y gamma

Permiten controlar cómo el modelo se adapta a los datos. El *kernel trick* es especialmente importante porque permite trabajar con relaciones no lineales y espacios de características muy complejos sin calcularlos directamente. SVM constituyen una herramienta poderosa dentro del ML clásico y sus conceptos también sirven de base para comprender otras técnicas mas adelante.

Capítulo 6 árboles de decisión

Son modelos versátiles que pueden utilizarse para clasificación, regresión y problemas con múltiples salida y son fundamentales para algoritmos de ensamble como los **Random Forests**, su funcionamiento es intuitivo: el modelo comienza en un nodo raíz y realiza preguntas sobre las características, por ejemplo: si una variable es menor que determinado valor. Según la respuesta, la observación avanza por diferentes ramas hasta llegar a una hoja, donde se encuentra la predicción.

No necesitan escalar ni centrar las características a diferencia de modelos como SVM o regresión lineal. En clasificación, cada nodo contiene información como el número de muestras, la distribución de clases y la **impureza de Gini** que indica qué tan mezcladas están las clases. Un nodo completamente puro tiene una impureza de Gini igual a cero.

Puede utilizarse la **entropía**, una medida relacionada con el desorden o la información. Ambas producen resultados similares aunque Gini suele ser ligeramente más rápida.

Scikit-Learn utiliza principalmente el algoritmo **CART** que busca en cada nodo la característica y el umbral que generan la división más pura posible. Después repite el proceso en los nodos resultantes. Este procedimiento es **voraz** porque selecciona la mejor división disponible en cada momento sin buscar necesariamente la mejor combinación para todo el árbol... encontrar el árbol óptimo es un problema computacionalmente muy complejo, por lo que se busca una solución suficientemente buena pero una vez entrenado se realizan predicciones rápido, ya que solo es necesario recorrer un camino desde la raíz hasta una hoja.

Los árboles también pueden estimar **probabilidades**, para una nueva observación, el modelo observa la distribución de clases de la hoja donde termina y utiliza esas proporciones como probabilidades, lo que significa que diferentes observaciones pueden recibir exactamente la misma predicción si terminan en la misma hoja.

Sobreajuste: los árboles son modelos no paramétricos, por lo que tienen gran libertad para adaptarse a los datos y pueden terminar memorizándolos, para controlar su complejidad existen hiperparámetros como:

- `max_depth`,
- `min_samples_split`,
- `min_samples_leaf`,
- `max_leaf_nodes` y
- `max_features`.

En general aumentar los valores mínimos o reducir los máximos produce árboles más simples y con menor riesgo de overfitting; y otra alternativa es la **poda** la cual consiste en eliminar partes del árbol que no aportan una mejora significativa. Los árboles también pueden utilizarse para **regresión**. En este caso, las hojas predicen normalmente el promedio del valor objetivo de las observaciones que llegan a ellas, mientras que CART busca realizar divisiones que reduzcan el MSE.

Sin restricciones, los árboles de regresión también pueden generar modelos demasiado complejos y poco generalizables.

Fronteras de decisión ortogonales, es decir, perpendiculares a los ejes de las características, por lo que pueden verse afectados cuando los datos están rotados. Además, son sensibles a pequeños cambios en los datos: modificar o eliminar algunas observaciones puede producir un árbol muy diferente, por ello aunque los árboles individuales son fáciles de interpretar y utilizar, su inestabilidad y tendencia al sobreajuste hacen especialmente útiles los métodos de ensamble que se estudiarán en los siguientes capítulos.

Conclusión: los árboles de decisión destacan por:

- sencillez,
- flexibilidad,
- facilidad de interpretación

Pero requieren controlar su complejidad para evitar el sobreajuste. Su importancia aumenta todavía más porque constituyen la base de modelos de ensamble como Random Forest que aprovechan múltiples árboles para obtener predicciones más estables y potentes.